

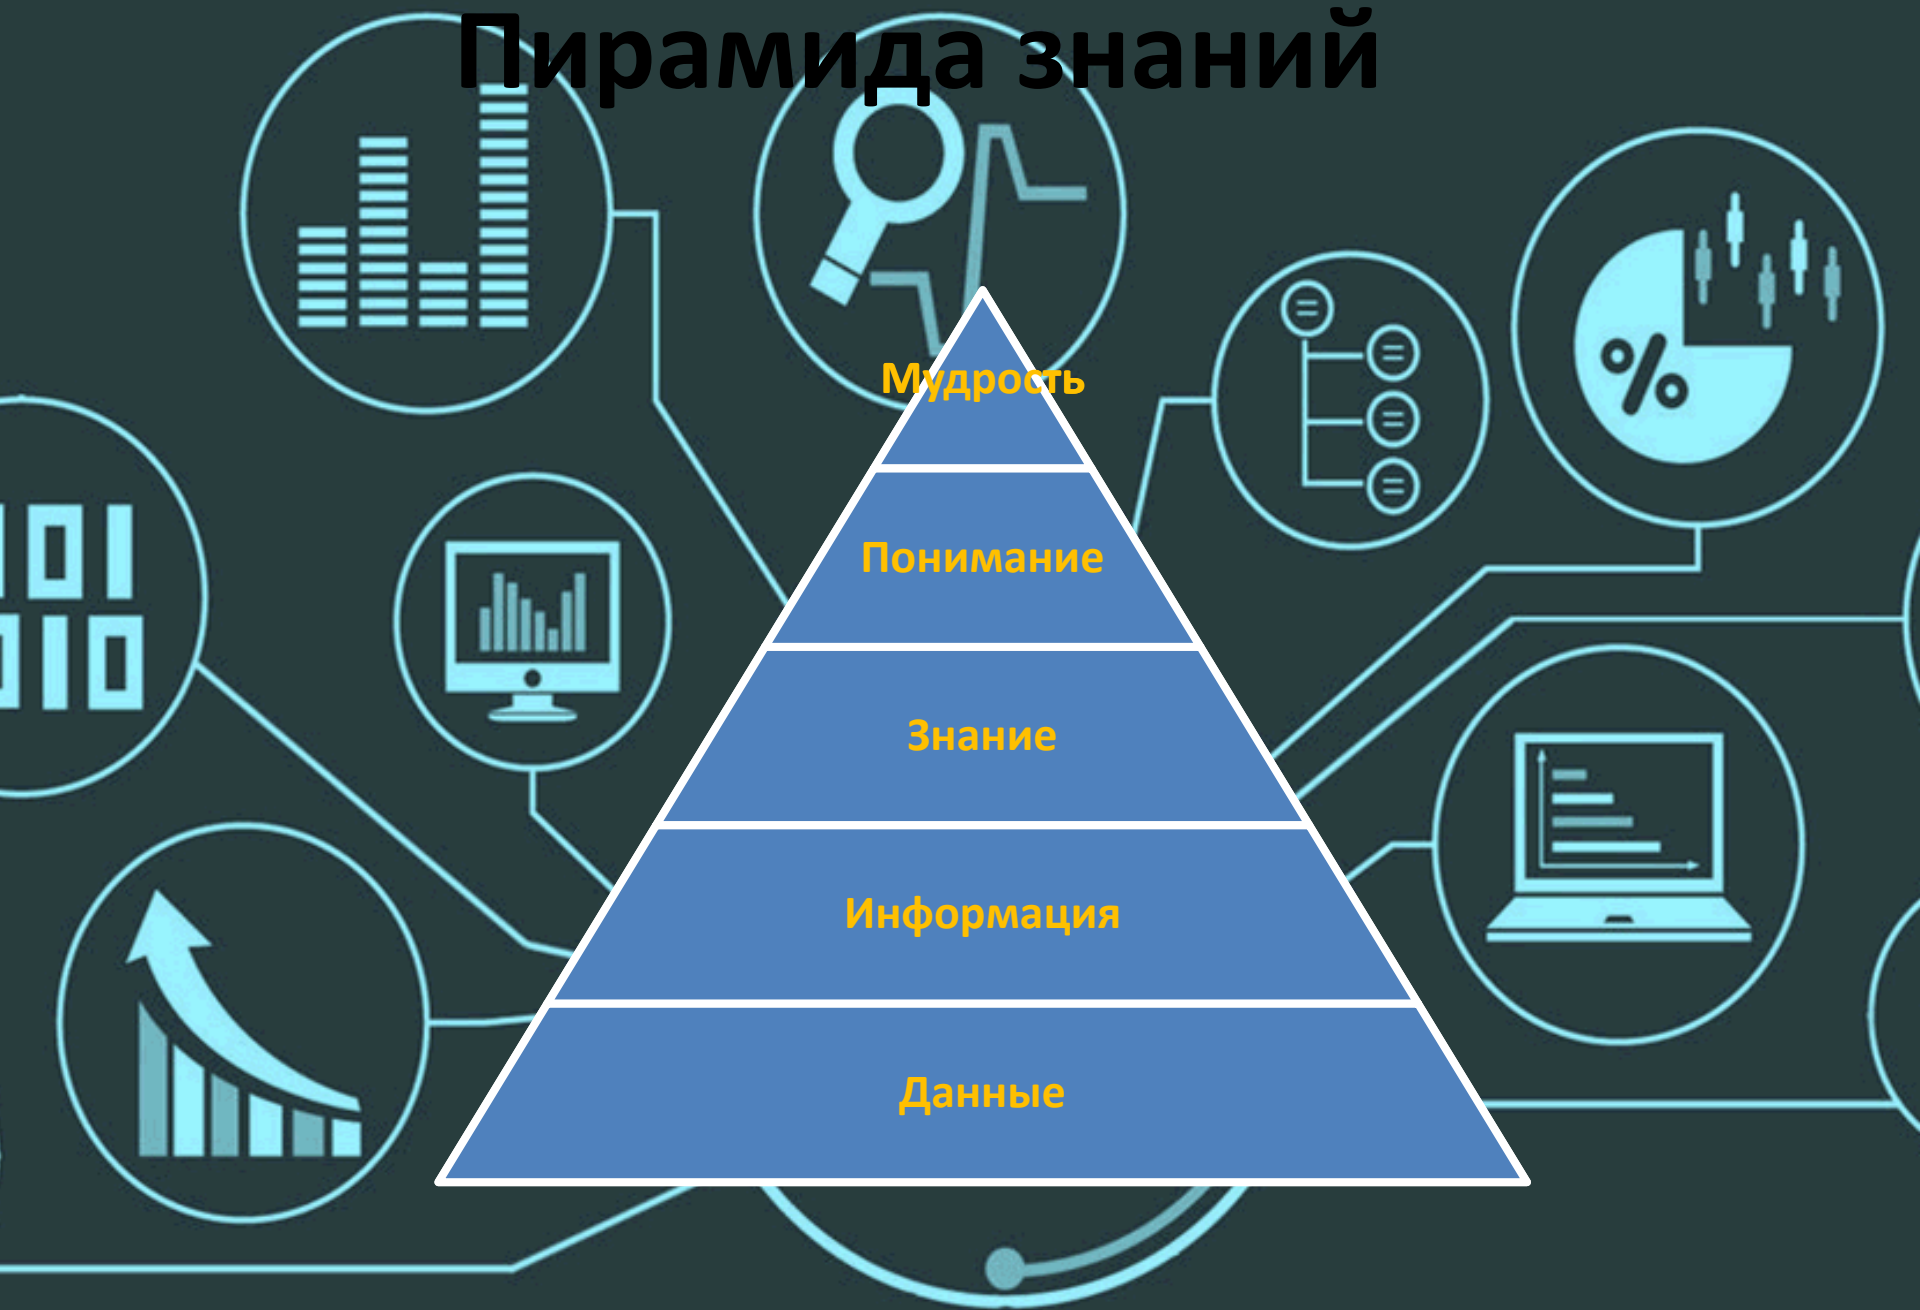


Методы работы с большими данными

Киреев Василий Сергеевич,
к.т.н., доцент

Москва, 2020

Пирамида знаний



DATA-driven

- **Data Driven** (дословно — «управляемый данными») — это подход к управлению, основанный на данных. Его главный постулат: решения нужно принимать, опираясь на анализ цифр, а не интуицию и личный опыт.

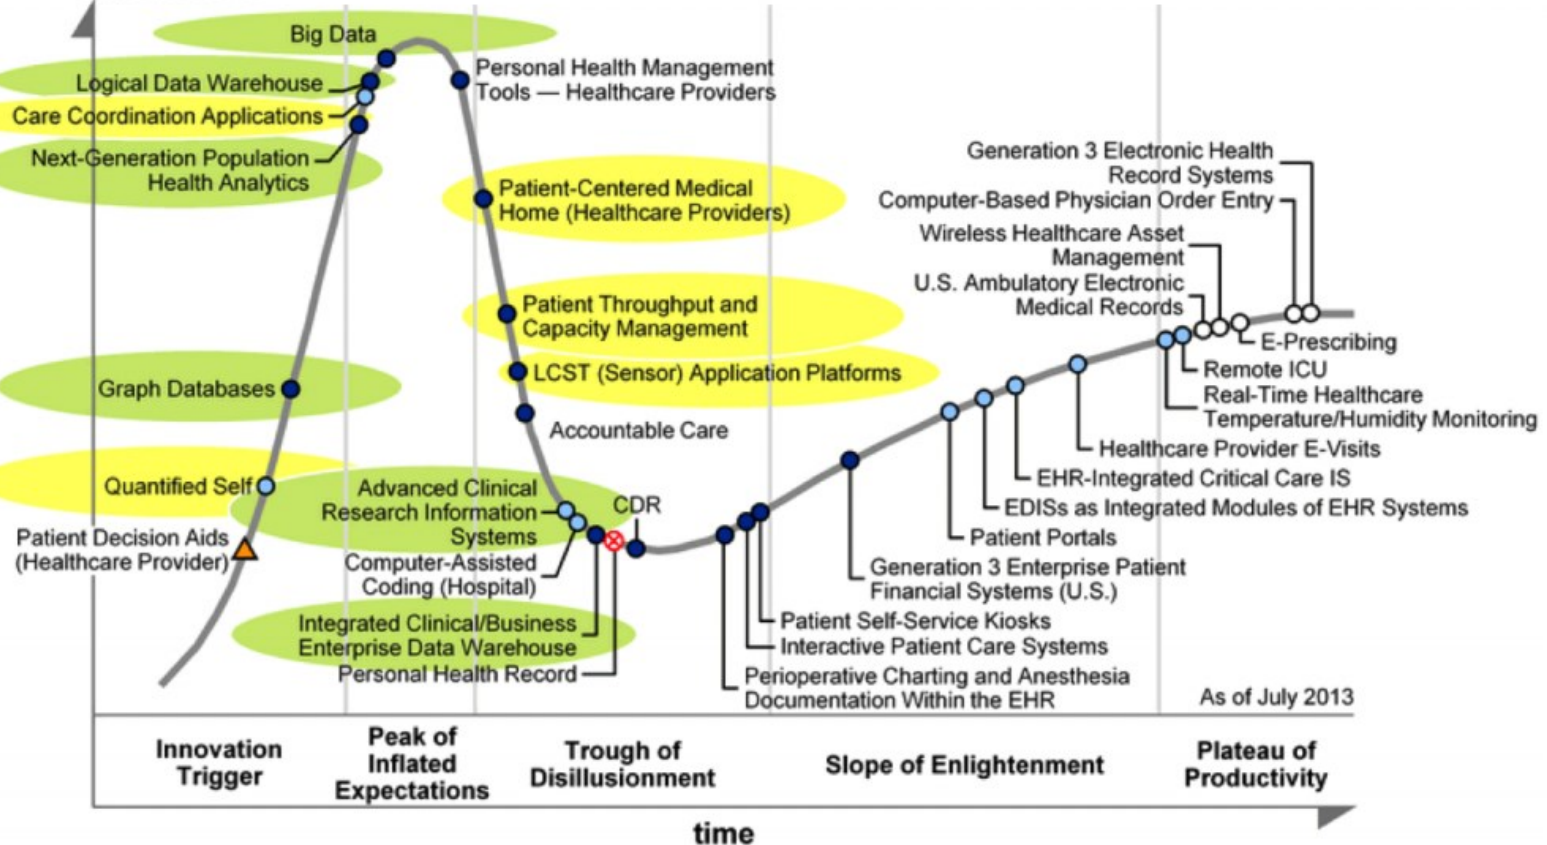


Большие Данные

- Big Data is a term used to describe the large amount of data in the networked, digitized, sensor-laden, information-driven world (*NIST*)
- Термин «Большие данные» относится к наборам данных, размер которых превосходит возможности типичных баз данных (БД) по занесению, хранению, управлению и анализу информации

Большие Данные

expectations



Plateau will be reached in:

○ less than 2 years

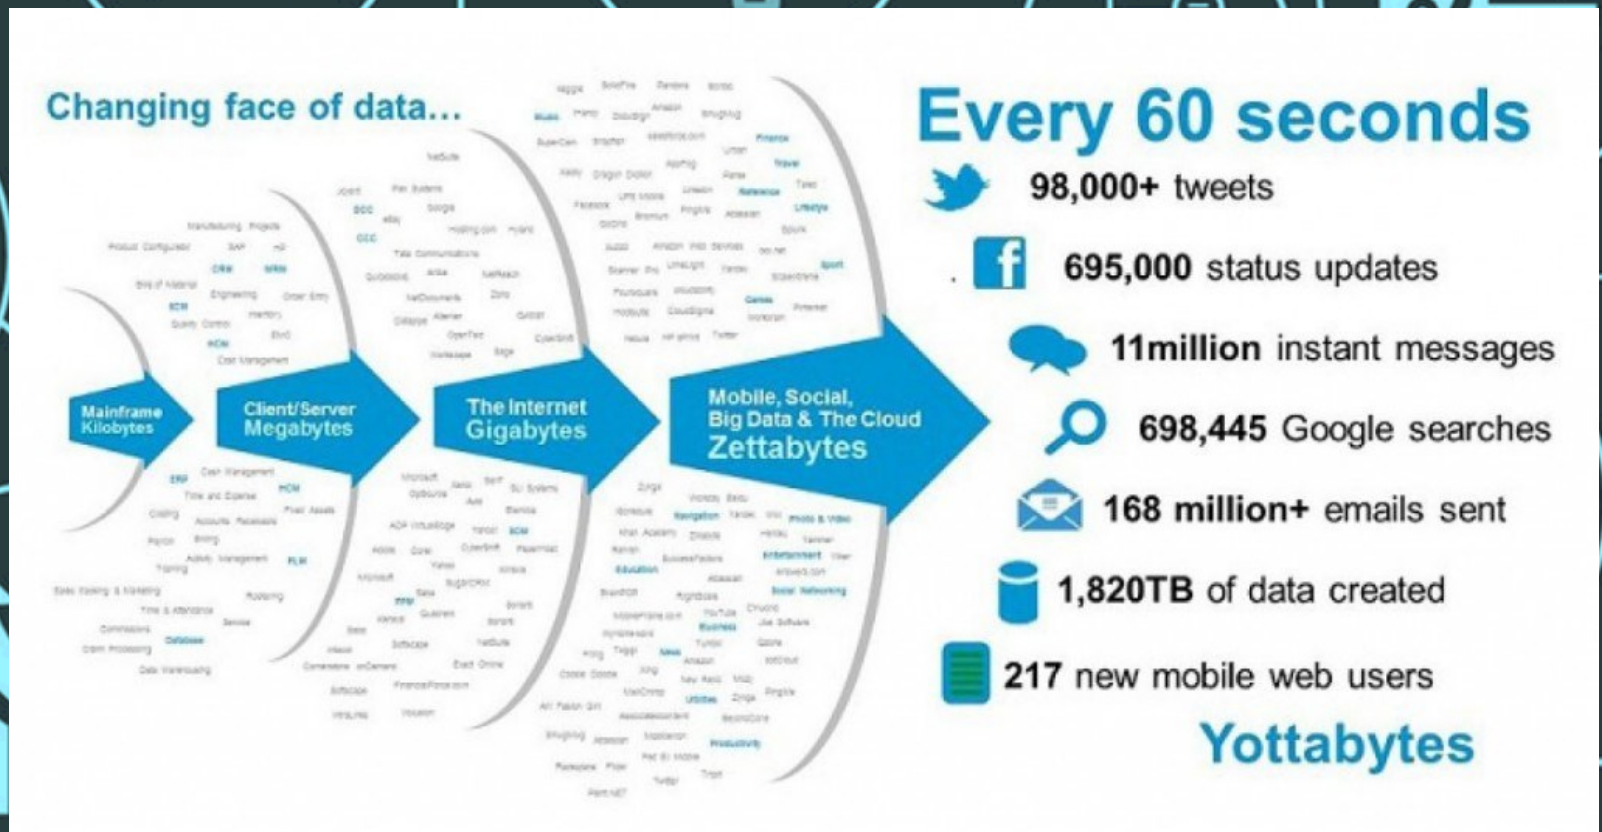
● 2 to 5 years

● 5 to 10 years

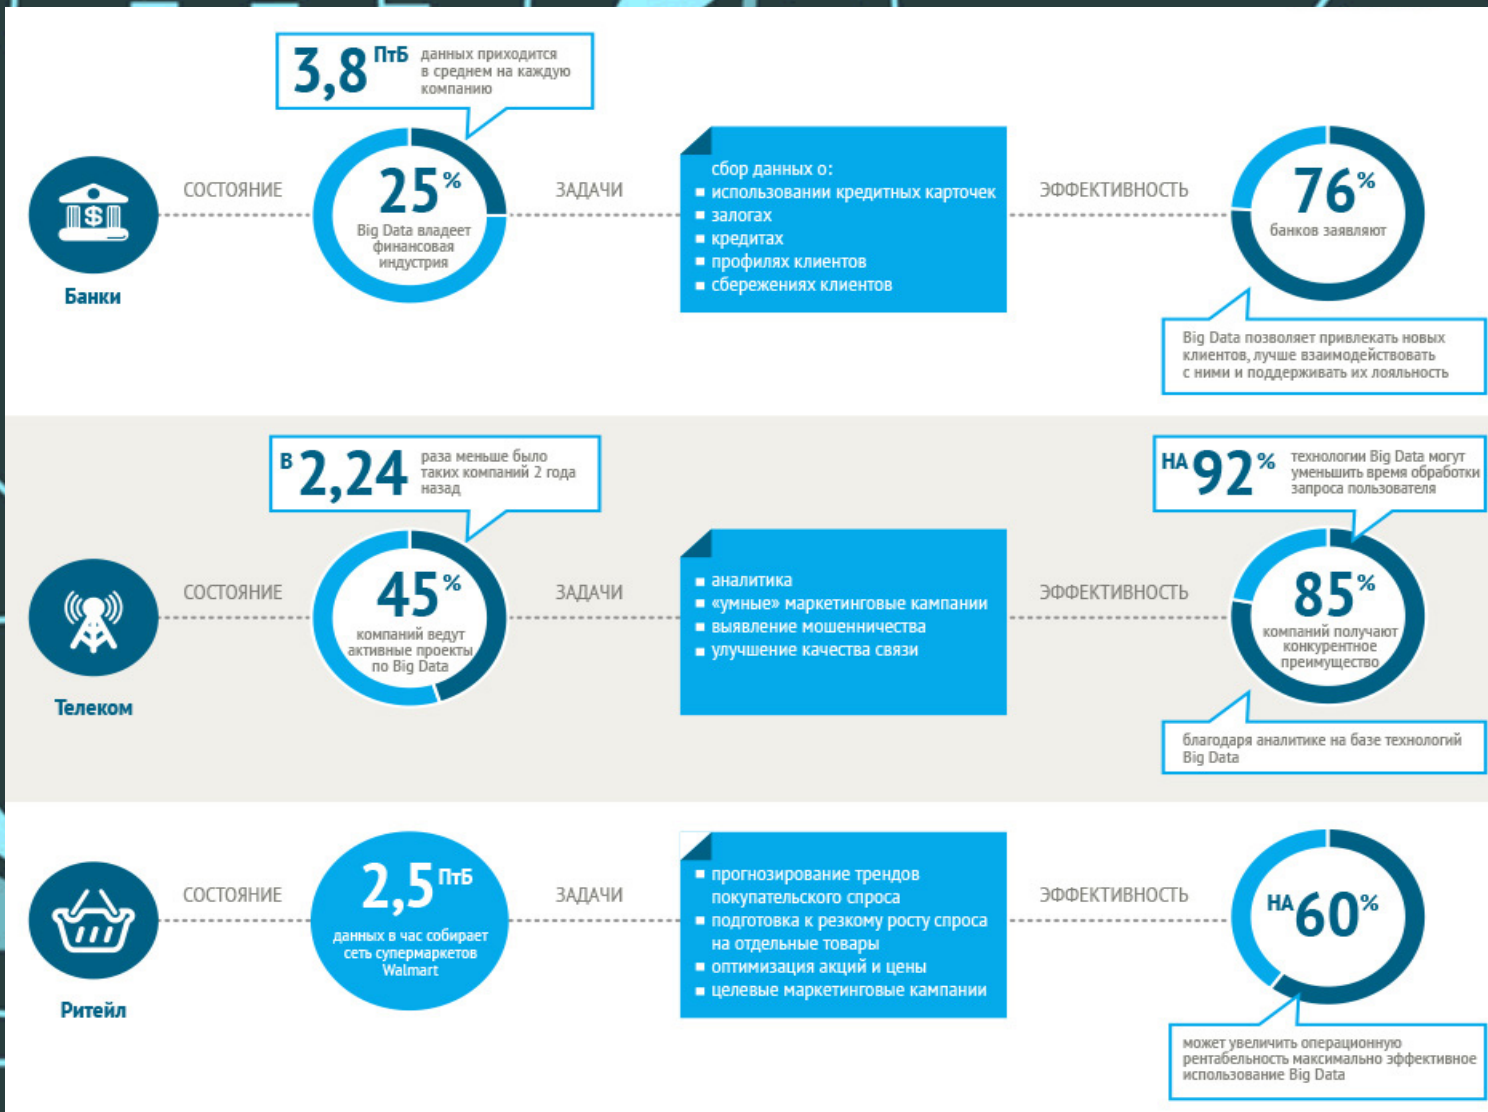
▲ more than 10 years

⊗ obsolete
before plateau

Что такое большие данные?



Большие данные в отраслях



Уровни архитектуры по обращению с Большими данными

Уровень сбора данных

Уровень визуализации


Уровень управления

Уровень хранения

Уровень инфраструктуры

Уровень сбора данных

Этот уровень отвечает за отделение шума от соответствующей информации, а также регулирование объема, скорости и разнообразия данных. Он должен иметь возможность проверять, очищать, преобразовывать, уменьшать и интегрировать данные в стек технологий больших данных для дальнейшей обработки. Это новое программное обеспечение, которое должно быть масштабируемым, устойчивым, отзывчивым и регулирующим в архитектуре больших данных.



**BIG
DATA**

Уровень инфраструктуры

На данном уровне располагается физическая инфраструктура, необходимая для функционирования и масштабируемости архитектуры больших данных. Фактически наличие надежной и недорогой физической инфраструктуры привело к появлению таких важных тенденций, как big data. Для поддержки непредвиденного или непредсказуемого объема, скорости или разнообразия данных физическая инфраструктура для больших данных должна отличаться от инфраструктуры для традиционных данных.

**BIG
DATA**

Уровень хранения

Использование массового распределенного хранилища и обработки является фундаментальным изменением в способе обработки больших данных предприятием. Распределенная система хранения данных обещает отказоустойчивость, а распараллеливание позволяет высокоскоростным алгоритмам распределенной обработки выполнять крупномасштабные данные. Для работы с «большими данными» используется несколько реализаций распределенных файловых систем. Основными из них можно считать реализацию от open-source проекта Hadoop (Hadoop Distributed File System - HDFS) и реализацию от Google (Google File System - GFS).

**BIG
DATA**

Уровень управления и обработки

На уровне управления и обработки находятся инструменты и языки запросов для доступа к базам данных NoSQL с помощью файловой системы хранения HDFS, находящейся поверх уровня физической инфраструктуры Hadoop. С развитием вычислительной техники, теперь можно управлять огромными объемами данных, которые ранее могли бы быть обработаны только суперкомпьютерами за большие деньги. Цены на системы (ЦП, ОЗУ и диск) упали. В результате, новые методы для распределенных вычислений стали основным направлением.


**BIG
DATA**

V-модель Больших Данных



Volume
24 мегабайт

- Гигабайты – 1024 мегабайт
- Терабайты – 1024 гигабайт
- Петабайты – 1024 терабайт
- Эксобайты – 1024 петабайт
- Зетабайты – 1024 эксобайт



1024 петабайт

1024 эксобайт

**BIG
DATA**

Variety

- Тексты
- Изображения
- Видео
- Аудио
- Показания датчиков
- Транзакции
- Гео-данные

BIG DATA



Velocity

- Пакетная обработка
- Стриминговая обработка
- Обработка в реальном времени

**BIG
DATA**



Veracity

- Отсутствие целостности
- Отсутствие полноты
- Отсутствие определенности



**BIG
DATA**

Value

- Статистическая ценность
- Финансовая ценность
- Ценность для продукта



BIG DATA

Validity

- Прозрачность
- Законность
- Конфиденциальность



**BIG
DATA**

Тренды в Больших Данных

DATA AGE - THE GLOBAL DATASPHERE 2025 TRENDS & DATA-READINESS FROM EDGE TO CORE

175 Zettabytes

The global datasphere will grow from 33 zettabytes in 2018 to 175 zettabytes by 2025. IoT devices are expected to create over 90 zettabytes of data in 2025.



49%

By 2025, 49% of all data worldwide will reside in public cloud environments as cloud becomes the new core.



30%

In 2025 nearly 30% of the world's data will need real-time processing as the role of the edge continues to grow.

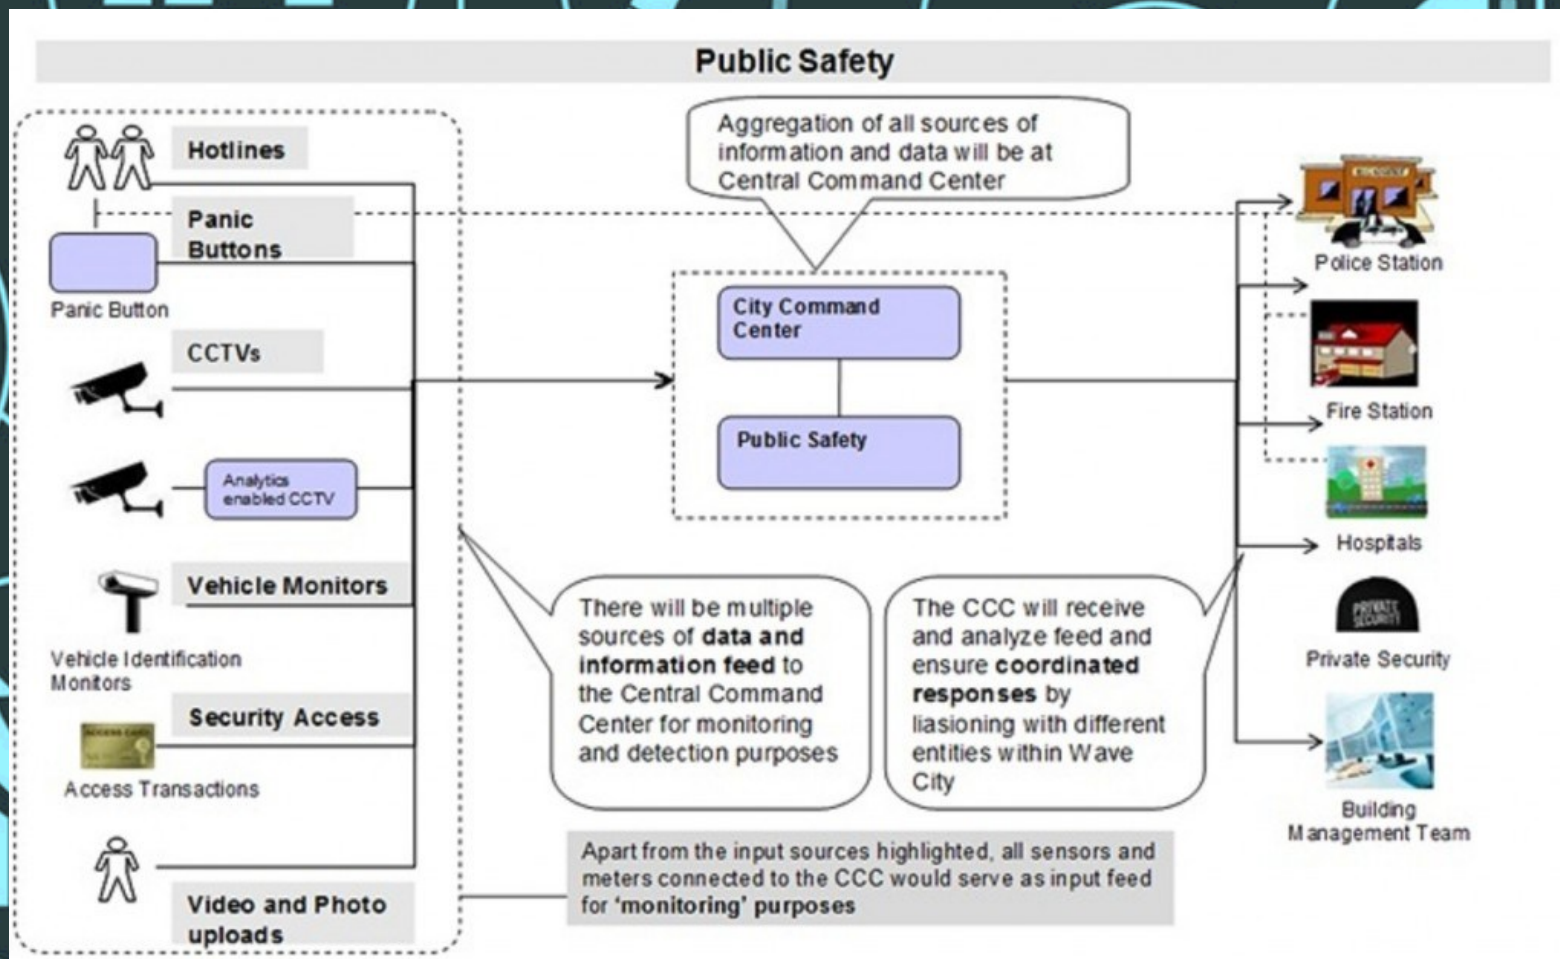
Применение Больших Данных

- Операционная аналитика
- Предиктивная аналитика
- Маркетинг
- Медицина
- Производство
- Государство
- Городская среда

**BIG
DATA**




Общественная безопасность



What Makes a Smart City?

Multiple Applications Create Big Data



40 TB per day (0.1% transmitted)

1 PB per day (0.2% transmitted)

50 PB per day (<0.1% transmitted)

10 MB per day (5% transmitted)

275 GB per day (1% transmitted)

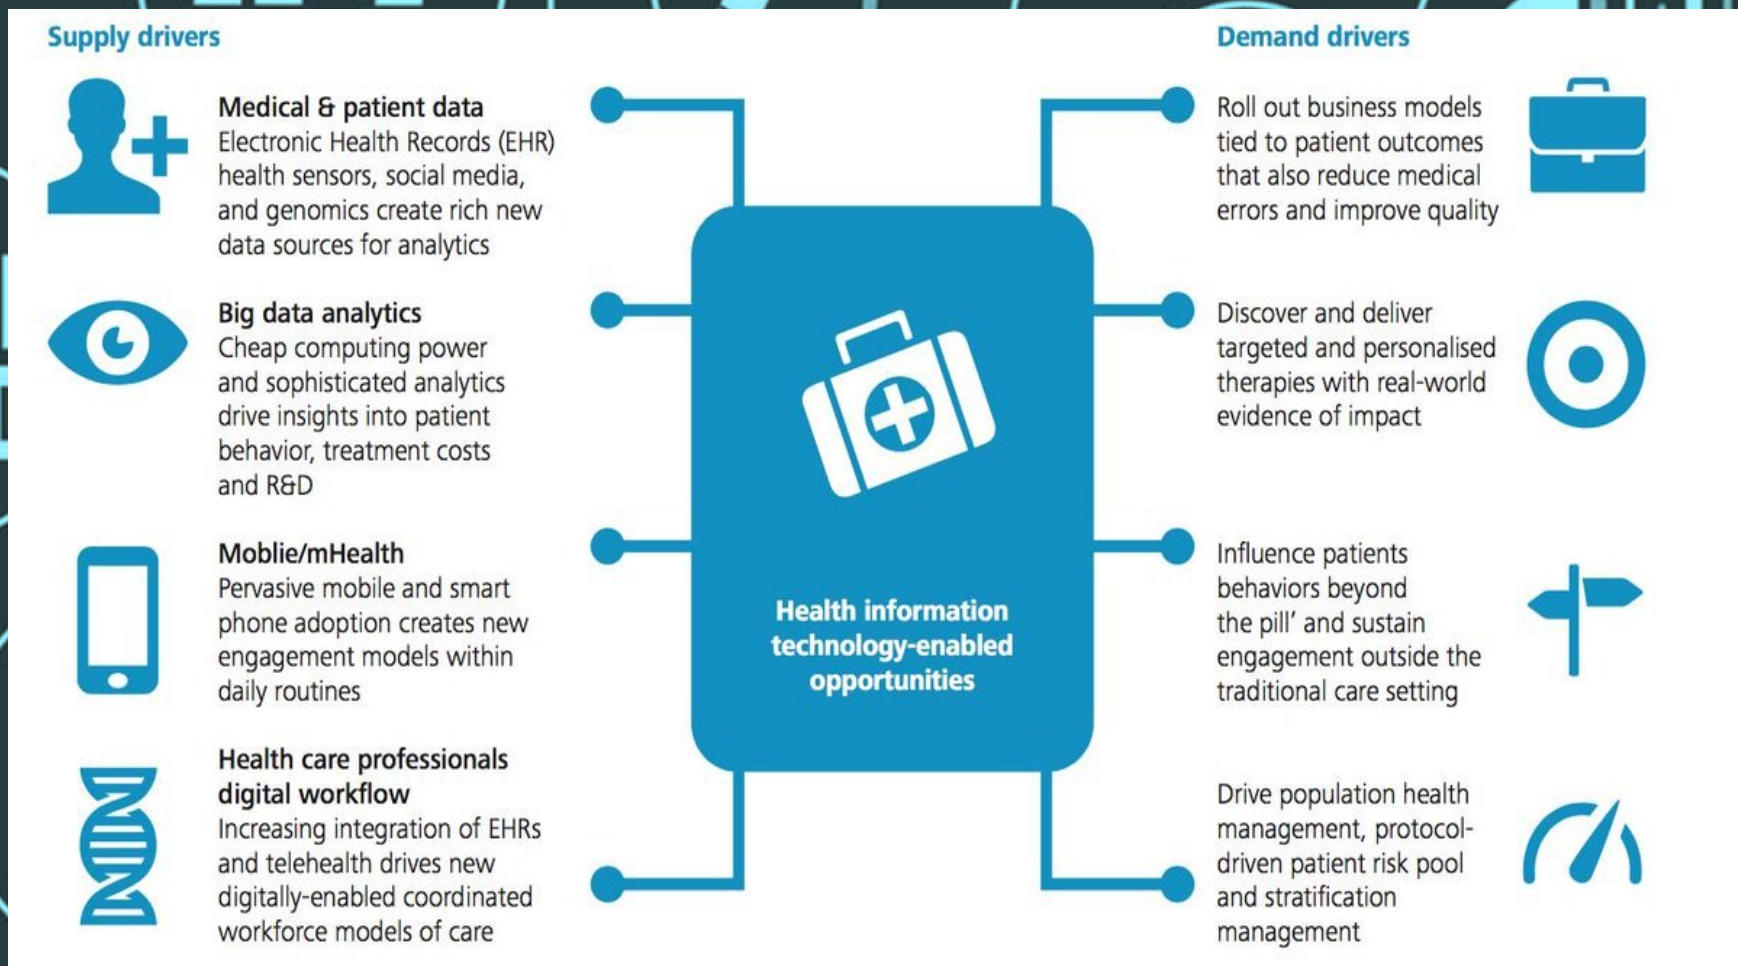
5 TB per day (0.1% transmitted)

70 GB per day (0.1% transmitted)

5 GB per day (1% transmitted)

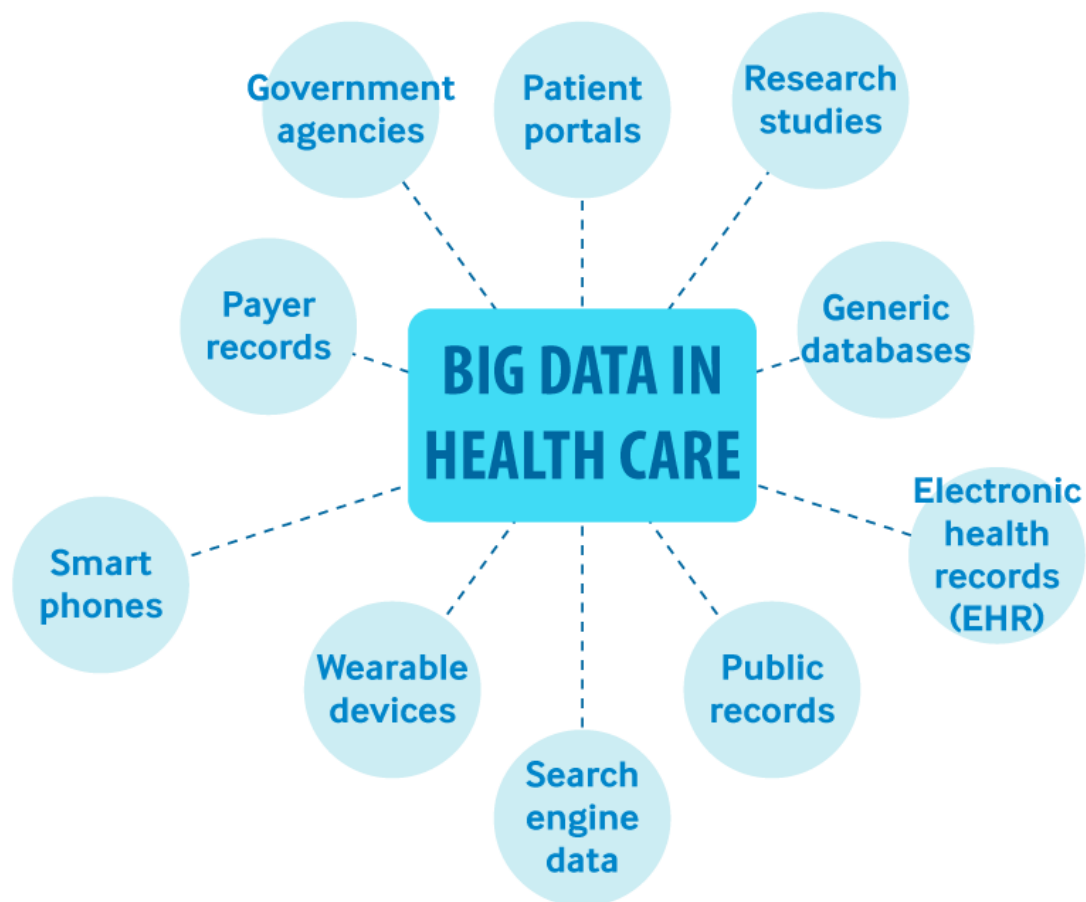
Source: Cisco Global Cloud Index, 2015-2020

Общественное здравоохранение

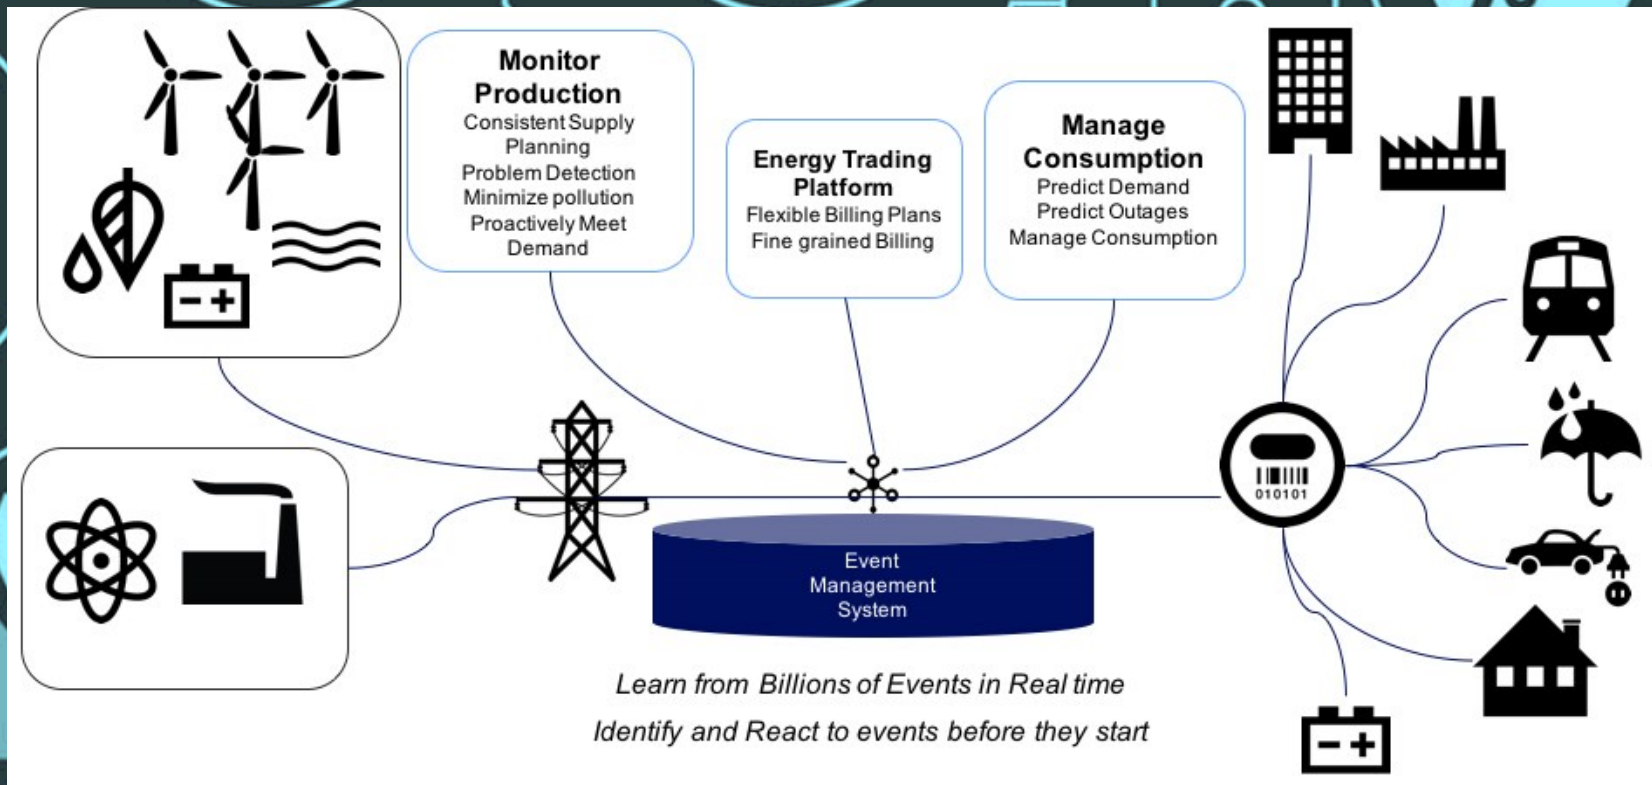


Общественное здравоохранение

Sources of Big Data in Health Care



Энергетика, окружающая среда и ЖКХ



Цифровые государственные услуги в мире

Governments Can Greatly Improve Usage and Satisfaction (I)

Very few services score well along both dimensions

COLOR = % WHO ARE SATISFIED IN 2016

- High satisfaction (70% or more)
- Medium satisfaction (50–69%)
- Low satisfaction (<50%)

SIZE = % WHO USED A SERVICE IN THE PAST TWO YEARS



AVERAGE USAGE OF ALL SERVICES (% of users)		Denmark	Estonia	France	Germany	Netherlands	Norway	Russia	Sweden	UK	US
Education	Interactions with public institutions	16	19	14	19	9	18	33	17	13	17
Health	Health care records	62	37	13	11	45	44	57	34	15	31
Immigration	Passport services	20	28	15	16	26	18	26	21	33	17
	Visa, residency, and work permits	6	5	6	9	6	15	5	9	12	8
Registries	Address updates	23	19	31	27	21	33	7	30	20	23
	Company information updates	26	49	19	15	11	18	26	15	13	17
Social services	Subsidy and benefit applications	23	19	17	18	23	26	13	20	19	28
	Payments to pensions	18	14	10	16	9	8	14	20	7	9
	Employment services and job searches	30	14	32	30	31	36	31	35	32	37
	Public-housing services	23	11	12	12	17	8	8	15	11	11
Taxes and customs	Electronic gates at border control checkpoints	4	7	6	8	5	10	0	4	16	5
	Tax returns	68	92	65	45	69	71	27	75	27	55
	Tax, rate, and fine payments	49	71	57	49	47	26	61	53	33	33
Transportation	Real-time information	54	72	69	58	36	60	60	65	50	51

Source: BCG 2016 Digital Government Satisfaction Survey.

Note: Of the 25 services covered in our survey, 15 are shown here. Usage means that a user completed at least some part of a transaction online. Each country may not allow end-to-end transactions online for a service. Survey question (usage): "Have you used the internet for the following interactions with government at least once in the past two years?" Respondents who answered "Yes" have been included. Survey question (satisfaction): "How satisfied are you with the use of the internet in delivering each kind of government service?" Response options range from 1 to 7, where 1 = "Extremely dissatisfied" and 7 = "Extremely satisfied." Respondents who selected 6 or 7 have been included as satisfied.

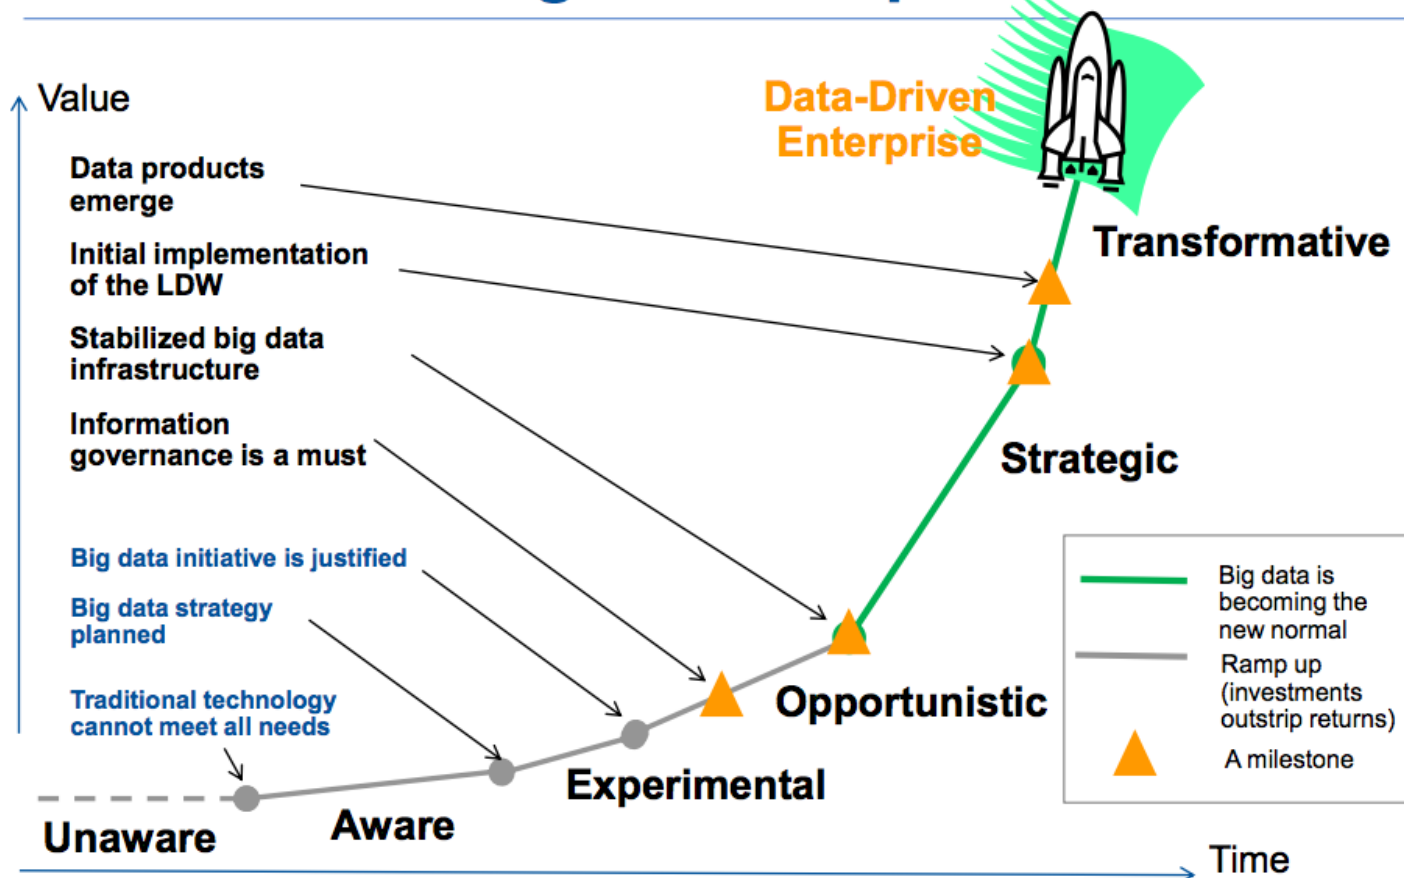
Большие данные в гос. управлении

- Открытые данные
- Оборона
- Защита прав потребителей
- Общественная безопасность
- Транспорт и городская инфраструктура
- Общественное здравоохранение
- Энергетика, окружающая среда и ЖКХ
- Образование

**BIG
DATA**

Внедрение Больших Данных

The Road Map: Typical Stages and Milestones of Big Data Adoption



Угрозы и риски использования Больших данных

риск
конфиденциальности

риск потери
данных

риск
переполнения
хранилища

риск снижения
эффективности
больших данных

риск
формирования
неэффективного
набора данных

риск
мошенничества

риск неготовности
к переменам

риск внешнего
консультанта

риск
экономической
нецелесообразности

риск ошибок
бизнес-модели

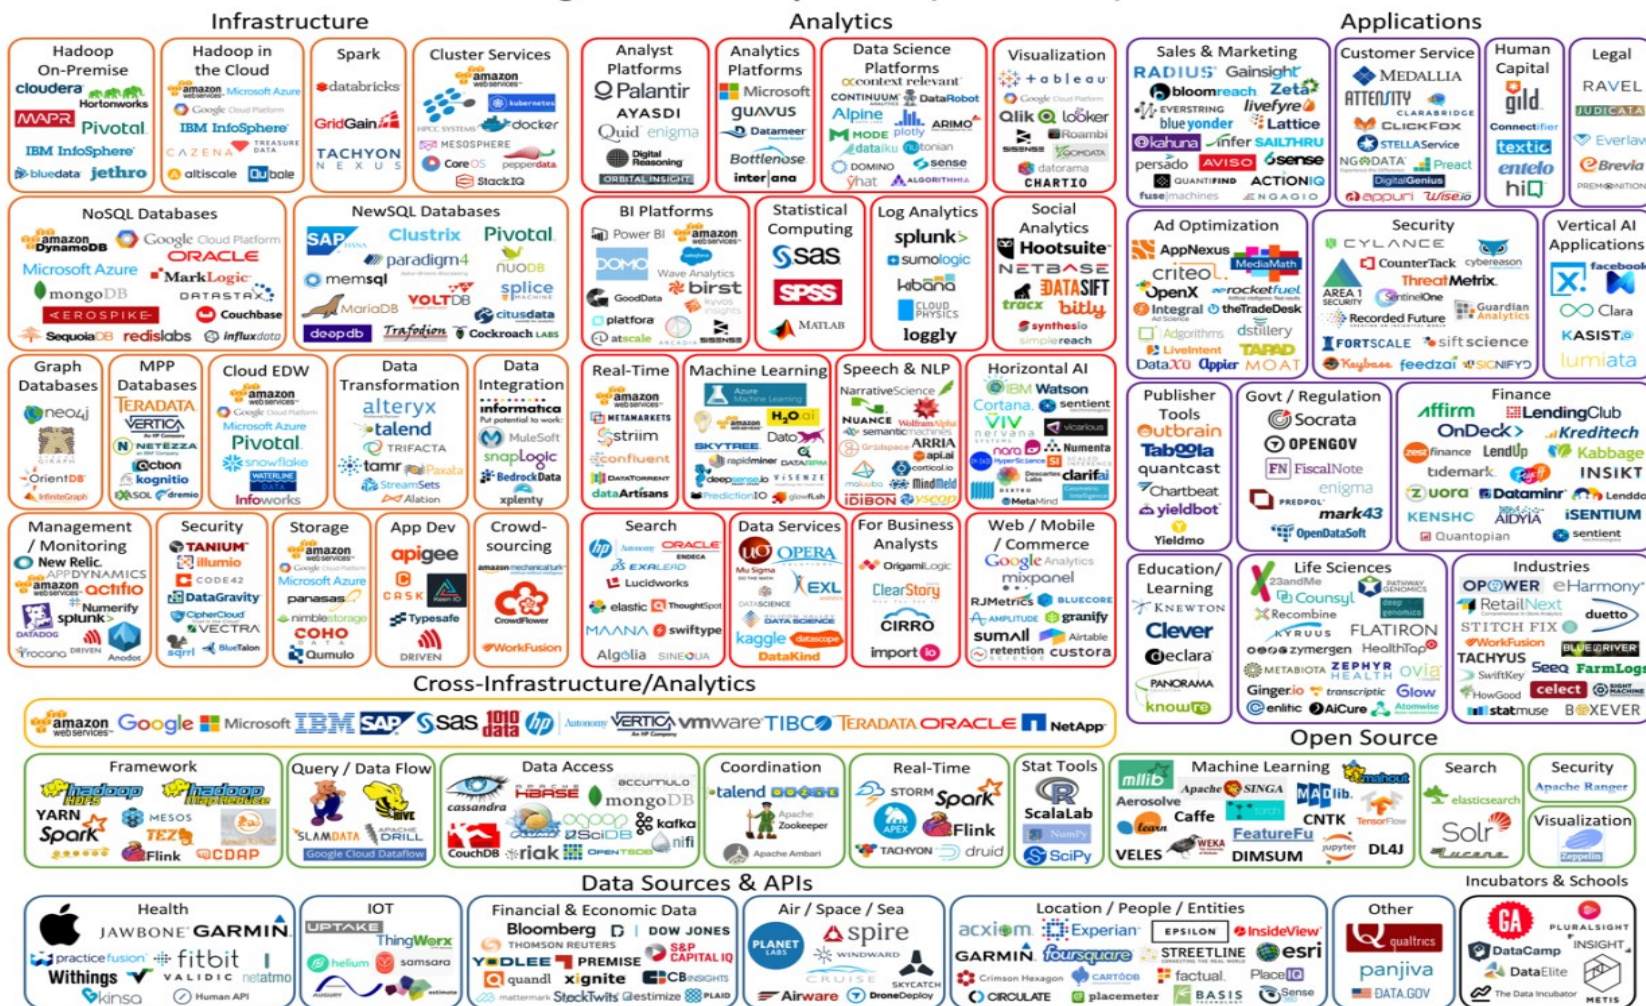
риск ошибок
больших данных

Снижение риска ошибок Больших данных

- проводить периодические ревизии данных
- контролировать ключевые параметры данных
- вести журнал выявленных ошибок и их устранения
- разрабатывать инструменты и алгоритмы устранения или нивелирования ошибок и некорректных состояний данных
- оценивать результативность инструментов
- проводить независимую оценку и экспертизу
- применять специальные средства тестирования данных и инструментов, которые разрабатываются самостоятельно
- использовать инструменты последовательно, подконтрольно и пошагово с постоянным контролем обрабатываемых данных в целом или по выборкам

Технологии

Big Data Landscape 2016 (Version 3.0)



Last Updated 3/23/2016

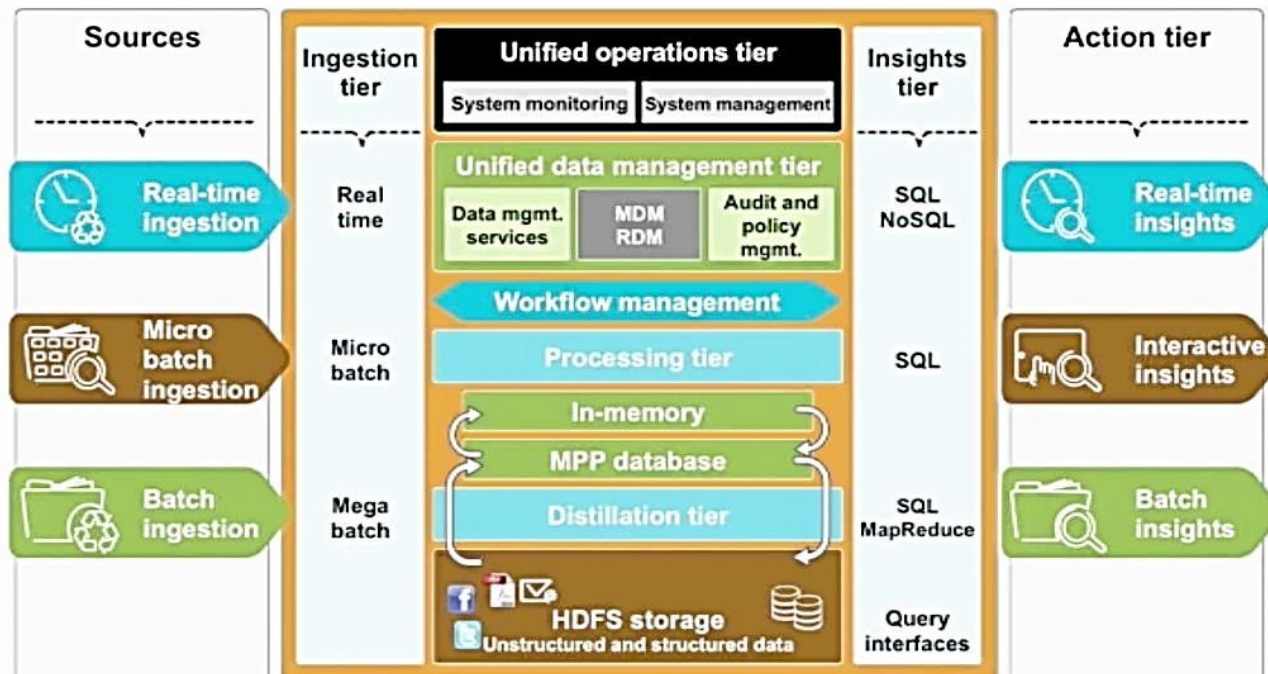
© Matt Turck (@mattturck), Jim Hao (@jimhao), & FirstMark Capital (@firstmarkcap)

FIRSTMARK

Data Lake

DATA SCIENCE
/CONFERENCE/ 2.0

Data Lake



Процесс работы с данными

Integrating big data into the traditional IT architecture

Multiple data sources

Mainframe
Relational databases
CRM
Supply chain management
ERP
Documents
Log files
External data feeds
Unstructured data
Internet and social media
Audio and video
Images

ETL

Traditional data warehousing components

Data extraction

Report server

Data mining

Data warehouse

Multi-dimensional cubes

Data marts

Business intelligence

Offload data and processing

Move high-value results

ELT

New big data components

Big data catalogues

Processing

Advanced analytics

Visualization and enterprise reporting

Dashboards

Standard reports

Ad hoc reports

Real-time analytics

Infographics

Export (pdf, xls, doc)

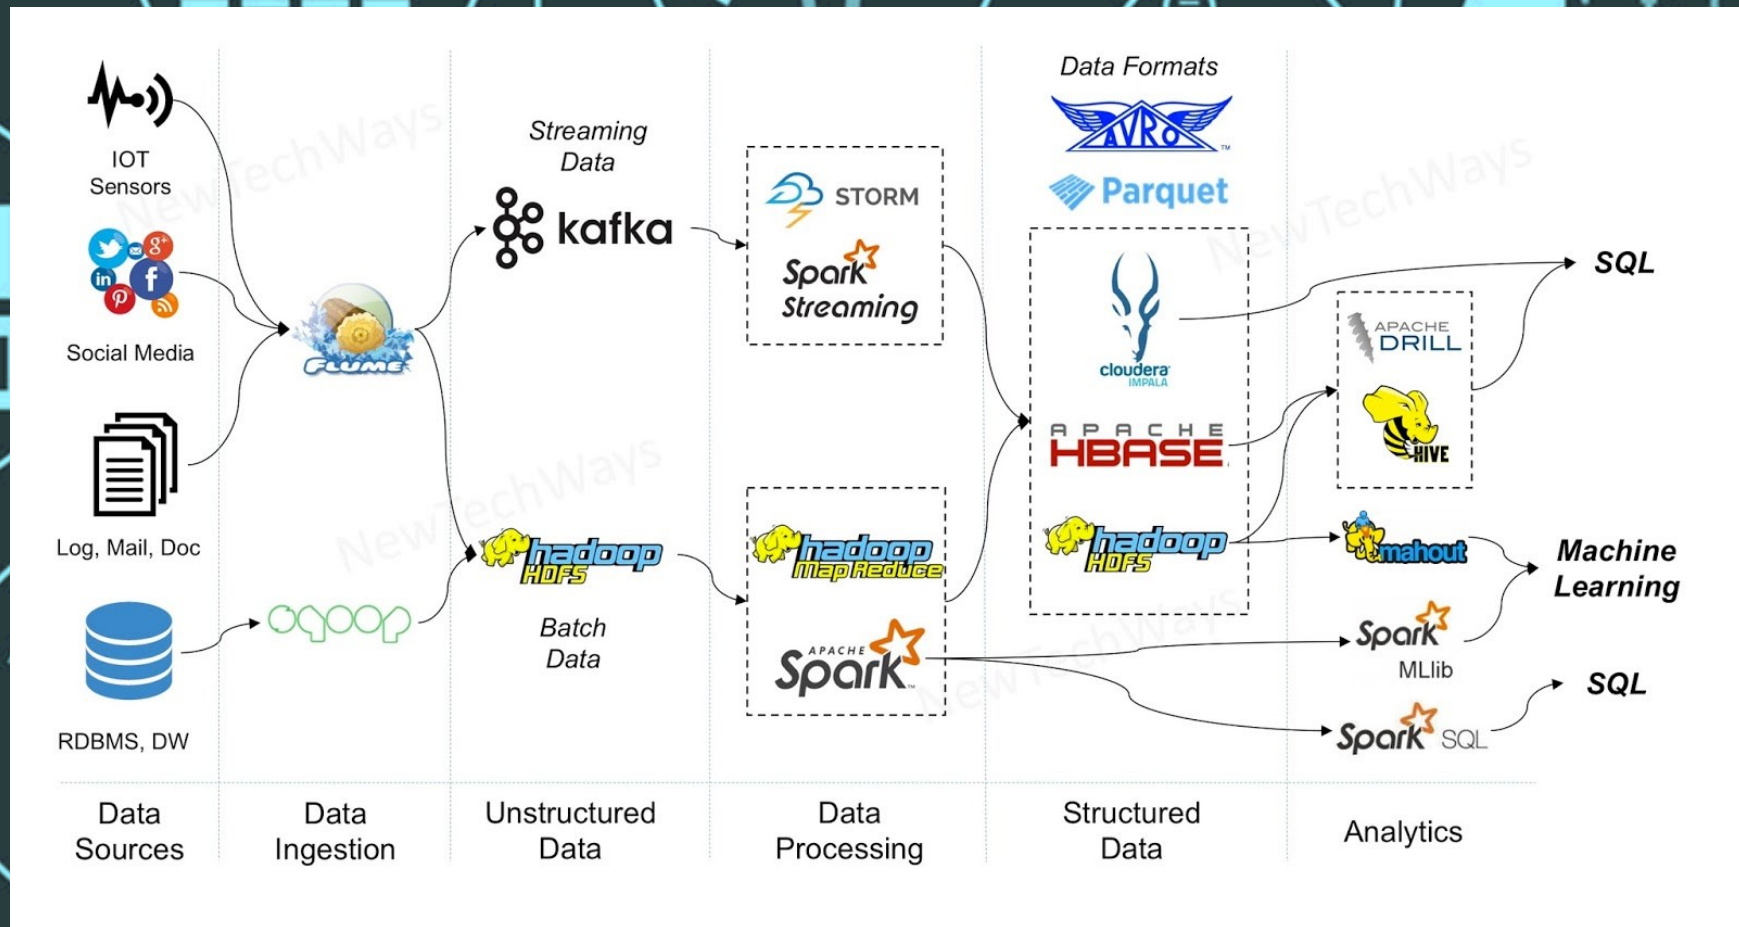
Collaboration

Analytics and segmented users

Business analysts
Business stakeholders
Executives
Decision makers
Database administrators
Data warehouse users
Administrators

Data science teams

Процесс Apache



Процесс Google

BigQuery: How Google handles BigData

A fully-managed data analytics service in the cloud.

Blazingly fast. Unlimited storage. Interactive analysis on multi-terabyte datasets.



Процесс Google

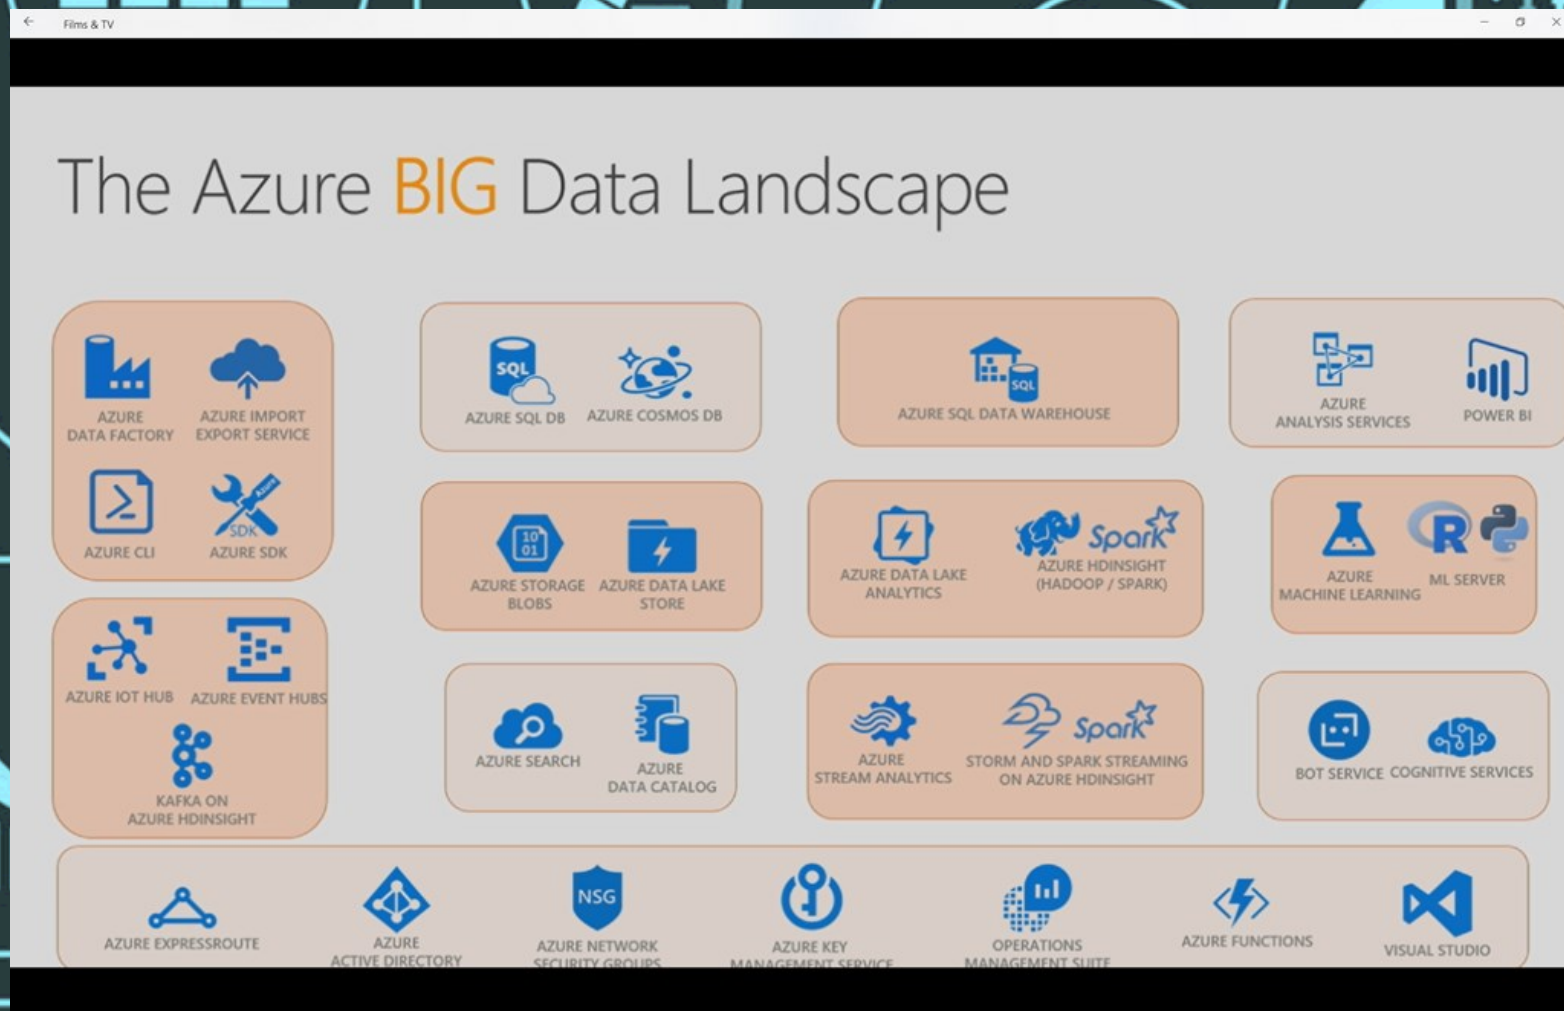
BigQuery: How Google handles BigData

A fully-managed data analytics service in the cloud.

Blazingly fast. Unlimited storage. Interactive analysis on multi-terabyte datasets.



Процесс Microsoft



Процесс Amazon

INGESTION



Amazon Kinesis



AWS Snowball



Database Migration Service



AWS Direct Connect

STORAGE



Amazon S3



Amazon DynamoDB



Amazon Redshift



Amazon RDS

PROCESS



EMR



EC2 (AMI)

SERVERLESS COMPUTE



Amazon Glue ETL & Catalog



Amazon Athena



AWS Lambda



Kinesis Firehose



Amazon Redshift Spectrum

VISUALIZE



Amazon QuickSight



Apache Zeppelin



Open source solutions



tableau

MicroStrategy

Vendor specific solutions

Процесс IBM

IBM Investor Briefing

IBM

IBM's Big Data Portfolio

Smarter Analytics / Business Analytics & Optimization

SPSS
Cognos

InfoSphere
BigInsights
Vivisimo

Optim
Guardium



Industry Solutions

- Financial Analytics
- Risk Analytics
- Threat & Fraud
- Workplace Analytics
- Customer Analytics

Business Intelligence

Performance Management

Content Management

Information Management Foundation

Client Services

Volume

Variety

Velocity

Veracity